ĐẠI HỌC PHENIKAA

TRƯỜNG CÔNG NGHỆ THÔNG TIN

BÀI TẬP LỚN: TÍCH HỢP VÀ PHÂN TÍCH DỮ LIỆU LỚN

Nhóm 6: Phân tích và dự báo trễ hạn giao hàng

Giảng viên hướng dẫn: ThS. Phạm Kim Thành.

Lớp: Tích hợp và phân tích dữ liệu lớn N03.

Thành viên nhóm:

1. Nguyễn Thị Thùy Linh – 23010633.
2. Nguyễn Thị Hải Yến – 23010624.

Hà Nội, 2026.

TÓM TẮT

Nghiên cứu khai thác bộ dữ liệu DataCo Smart Supply Chain nhằm mô tả thực trạng giao hàng trễ và xây dựng mô hình dự báo rủi ro ở cấp đơn hàng. Quy trình gồm tiền xử lý và tích hợp dữ liệu bằng PySpark, phân tích bằng Spark SQL, huấn luyện mô hình bằng Spark MLlib và trực quan hóa kết quả qua Dashboard Streamlit. Sau khi tổng hợp, tập phân tích có 65.752 đơn hàng, trong đó 36.048 đơn giao trễ (54,82%). Mô hình Random Forest cuối cùng sử dụng 5 đặc trưng, đạt Accuracy 69,49% và ROC-AUC 0,7345 trên tập kiểm thử. Kết quả cho thấy tiềm năng hỗ trợ nhận diện rủi ro, đồng thời phản ánh giới hạn của dữ liệu lịch sử hiện có.

1. GIỚI THIỆU

1.1. Bối cảnh và vấn đề nghiên cứu

Trong chuỗi cung ứng, giao hàng trễ có thể làm giảm trải nghiệm khách hàng và gây khó khăn cho kế hoạch vận hành. Dữ liệu giao dịch lưu trữ nhiều dấu hiệu liên quan đến đơn hàng, khu vực, phương thức vận chuyển và lịch giao hàng. Việc phân tích các dấu hiệu này giúp mô tả những nhóm có rủi ro cao và xây dựng công cụ dự báo hỗ trợ quyết định.

Bài toán được đặt ra là: từ các thông tin đã biết tại thời điểm dự báo, có thể phân loại một đơn hàng thuộc nhóm có nguy cơ giao trễ hay không? Nghiên cứu tập trung vào mô hình học máy thực nghiệm, không khẳng định quan hệ nhân quả giữa một yếu tố và sự chậm trễ.

1.2. Mục tiêu và đóng góp

Đề tài được triển khai theo hướng một quy trình xử lý dữ liệu hoàn chỉnh thay vì chỉ xây dựng một mô hình phân loại. Đầu vào là tập dữ liệu giao dịch DataCo, đầu ra gồm các bảng dữ liệu tích hợp, kết quả phân tích theo nhóm tiêu chí, mô hình đã huấn luyện và một giao diện trực quan để trình bày. Cách tổ chức này cho phép người đọc lần theo từng bước từ dữ liệu ban đầu đến kết quả cuối cùng.

Các nhiệm vụ cụ thể được nhóm phân chia thành: tìm hiểu cấu trúc dữ liệu; kiểm tra chất lượng; chuẩn hóa và tổ chức bảng; thực hiện các truy vấn tổng hợp bằng Spark SQL; lựa chọn đặc trưng phục vụ dự báo; so sánh các phương án huấn luyện; đánh giá trên tập kiểm tra; xuất dữ liệu và xây dựng Dashboard. Kết quả của từng nhiệm vụ được lưu để có thể kiểm tra độc lập.

Nghiên cứu hướng đến bốn mục tiêu: (i) kiểm tra và làm sạch dữ liệu; (ii) tổ chức các bảng liên kết và lưu trữ định dạng Parquet; (iii) phân tích tình trạng giao trễ theo các chiều nghiệp vụ; (iv) xây dựng, đánh giá mô hình dự báo và trình bày kết quả trên Dashboard.

1.3. Phạm vi nghiên cứu

Đối tượng nghiên cứu là các bản ghi đơn hàng trong bộ dữ liệu DataCo Smart Supply Chain. Hệ thống được thực hiện theo hình thức xử lý theo lô trên Google Colab, sử dụng Google Drive để lưu trữ tệp. Đây là quy trình phân tích dữ liệu và mô hình minh họa, chưa phải hệ thống dự báo vận hành thời gian thực.

2. DỮ LIỆU VÀ PHƯƠNG PHÁP

2.1. Nguồn dữ liệu

Dữ liệu được đọc vào Spark DataFrame để tận dụng khả năng xử lý bảng và hệ thống kiểu dữ liệu của PySpark. Nhóm quan sát số lượng bản ghi, số cột, tên trường, kiểu dữ liệu và một số dòng

mẫu trước khi thực hiện phép biến đổi. Các trường quan trọng phục vụ bài toán gồm mã đơn hàng, mã dòng sản phẩm, thông tin khách hàng, ngày đặt hàng, ngày giao hàng, khu vực, phương thức vận chuyển và nhãn rủi ro giao trễ.

Một điểm cần phân biệt là dữ liệu gốc được ghi ở mức dòng sản phẩm trong đơn hàng, trong khi nhiều kết quả phân tích cần thực hiện ở mức đơn hàng. Nếu đếm trực tiếp từng dòng sản phẩm thì đơn có nhiều sản phẩm có thể bị tính nhiều lần. Vì vậy, nhóm xác định rõ khóa đơn hàng và mức tổng hợp tương ứng cho từng bảng kết quả.

Dữ liệu đầu vào là tệp CSV DataCo Smart Supply Chain với 180.519 dòng ở mức chi tiết mặt hàng. Dữ liệu bao gồm thông tin khách hàng, đơn hàng, sản phẩm, địa lý, thời gian và phương thức vận chuyển. Các bước kiểm tra tập trung vào kiểu dữ liệu, giá trị thiếu, bản ghi trùng, khóa liên kết và tính hợp lệ của nhãn giao trễ.

2.2. Quy trình xử lý

Trong bước nhập dữ liệu, nhóm chủ động in schema và xem trước các bản ghi để kiểm tra việc suy luận kiểu. Đối với CSV có nhiều trường, tên cột có khoảng trắng hoặc ký tự đặc biệt dễ gây khó khăn khi viết truy vấn, nên nhóm chuẩn hóa tên trường về một quy tắc thống nhất. Sau chuẩn hóa, mỗi phép biến đổi đều được kiểm tra bằng số dòng hoặc bảng mẫu. Cách thực hiện tuần tự trong notebook giúp phát hiện lỗi ngay tại bước phát sinh thay vì chờ đến cuối quy trình.

Quy trình cũng được chia thành các phần rõ ràng trong Colab: thiết lập môi trường; khám phá và tiền xử lý; thiết kế và tích hợp; phân tích SQL; huấn luyện mô hình; thử nghiệm đặc trưng; lưu kết quả; trực quan hóa; xuất Dashboard; kết luận. Việc đặt tiêu đề và ghi nhận xét dưới từng ô kết quả giúp người xem không cần đọc toàn bộ mã nguồn vẫn hiểu mục đích của bước xử lý và ý nghĩa của đầu ra.

Quy trình bắt đầu bằng kết nối Google Drive trong Colab và khởi tạo SparkSession. Sau khi đọc CSV, nhóm chuẩn hóa tên cột để tránh lỗi khi viết truy vấn SQL, chuyển các trường số và thời gian sang kiểu dữ liệu phù hợp, rồi kiểm tra giá trị thiếu, bản ghi trùng và giá trị bất hợp lệ. Bước kiểm tra được thực hiện trước khi xây dựng các bảng quan hệ để giảm nguy cơ lan truyền lỗi sang kết quả tích hợp.

Sau giai đoạn làm sạch, dữ liệu được tách thành các bảng chủ đề và ghép lại qua các khóa liên kết. Bảng tích hợp được lưu ở định dạng Parquet, đồng thời đăng ký các Spark SQL temporary view để sử dụng trong phân tích. Từ các bảng này, nhóm tạo bộ dữ liệu cho học máy, huấn luyện mô hình, xuất chỉ số đánh giá và cuối cùng chuẩn bị các CSV dùng cho Dashboard.

Quy trình thực nghiệm: CSV gốc → PySpark tiền xử lý → tách và liên kết các bảng thực thể → Parquet tích hợp → Spark SQL phân tích → tạo tập dữ liệu cấp đơn hàng → Spark MLlib huấn luyện và đánh giá → xuất dữ liệu cho Streamlit.

2.3. Thiết kế dữ liệu tích hợp

Đối với bảng khách hàng, nhóm giữ các thuộc tính phục vụ nhận diện và phân nhóm. Bảng sản phẩm lưu mã sản phẩm và các thuộc tính mô tả; bảng đơn hàng lưu thông tin thời gian và khu vực; bảng dòng

sản phẩm thể hiện quan hệ giữa đơn và mặt hàng; bảng vận chuyển mô tả phương thức và thời gian giao; bảng khu vực hỗ trợ tổng hợp theo vùng. Mỗi bảng có khóa riêng và được kiểm tra khả năng liên kết với bảng còn lại.

Để tạo dữ liệu phục vụ phân tích, nhóm sử dụng phép JOIN theo các khóa đã xác định. Kết quả tích hợp được đối chiếu với số dòng gốc và số đơn khác nhau. Việc giữ riêng cả các bảng thành phần và bảng tích hợp mang lại hai lợi ích: có thể tái hiện quy trình quan hệ dữ liệu, đồng thời rút ngắn thời gian cho những truy vấn mô tả vốn cần thông tin từ nhiều bảng.

Sáu bảng được tổ chức theo các nhóm thông tin khách hàng, sản phẩm, đơn hàng, dòng sản phẩm, vận chuyển và khu vực. Cách tách bảng giúp mô tả rõ thực thể, hạn chế lặp thông tin và thuận lợi khi kiểm tra khóa. Các phép nối được thiết kế theo khóa tương ứng; sau mỗi bước nhóm kiểm tra số lượng dòng và giá trị khóa để phát hiện tình trạng nhân bản hoặc mất bản ghi.

Khi tạo bảng dữ liệu tích hợp, cần phân biệt dữ liệu dùng để giải thích lịch sử giao hàng với dữ liệu có thể biết tại thời điểm dự báo. Thông tin phát sinh sau khi đơn hàng hoàn tất không nên được đưa vào đặc trưng đầu vào, bởi việc đó có thể làm kết quả kiểm thử cao giả tạo và không phù hợp với mục tiêu dự báo sớm.

Sáu bảng thực thể được tổ chức gồm customers, products, orders, order_items, shipping và regions. Các bảng được liên kết để tạo tập integrated_data, phục vụ truy vấn nhiều chiều. Việc kiểm tra khóa ngoại và số lượng bản ghi sau JOIN giúp hạn chế mất dữ liệu hoặc nhân bản không mong muốn.

Thành phần	**Số bản ghi**
Khách hàng	20.652
Sản phẩm	118
Đơn hàng	65.752
Chi tiết đơn	180.519
Vận chuyển	65.752
Vùng/quốc gia	167

Đơn hàng là đơn vị phân tích chính cho bài toán dự báo; các bản ghi chi tiết mặt hàng được tổng hợp trước khi huấn luyện để tránh đếm một đơn nhiều lần.

3. TIỀN XỬ LÝ VÀ TÍCH HỢP

3.1. Kiểm tra chất lượng dữ liệu

Kiểm tra giá trị thiếu được thực hiện theo từng cột thay vì chỉ tính tổng số ô rỗng. Cách này giúp xác định trường nào ảnh hưởng trực tiếp đến phép JOIN, trường nào chỉ là thông tin bổ sung. Với khóa chính và khóa ngoại, nhóm ưu tiên xác minh tính đầy đủ và tính duy nhất. Với những thuộc tính ít thiếu và không ảnh hưởng đến phân tích chính, quyết định xử lý được cân nhắc để tránh loại bỏ quá nhiều bản ghi hợp lệ.

Kiểm tra tính hợp lệ tập trung vào các mối quan hệ logic: thời điểm giao hàng phải được diễn giải đúng kiểu ngày giờ, số ngày vận chuyển không thể âm, nhãn phân loại phải thuộc miền giá trị cho phép, và các mã liên kết phải tìm được bản ghi tương ứng. Sau khi hoàn thành, nhóm mới lưu kết quả sạch sang Parquet. Nhờ vậy, những phần phân tích và học máy sau đó sử dụng chung một nền dữ liệu.

Nhóm thực hiện các phép đếm số lượng bản ghi, số lượng giá trị rỗng theo cột, số khóa đơn hàng khác nhau và số trường hợp trùng khóa. Với các cột ngày giờ, nhóm chuyển đổi định dạng và kiểm

tra tính hợp lệ; với trường thời gian vận chuyển, nhóm đối chiếu miền giá trị để phát hiện dữ liệu âm hoặc bất thường. Những kiểm tra này giúp xác nhận tập dữ liệu có thể dùng cho các bước phân tích tiếp theo.

Bên cạnh việc kiểm tra từng bảng, nhóm còn đánh giá tính nhất quán giữa các bảng thông qua khóa ngoại. Kết quả kiểm tra được hiển thị ngay dưới các ô code trong notebook. Việc giữ lại bảng kết quả trung gian giúp người đọc xác minh rằng phép nối dữ liệu không làm sai số lượng đơn hàng hay làm mất các đối tượng quan trọng.

Nhóm đọc dữ liệu bằng PySpark, chuẩn hóa tên cột, chuyển đổi kiểu số và thời gian, đồng thời kiểm tra tỷ lệ thiếu. Trong tập dữ liệu đã chuẩn hóa, nhãn late_delivery_risk có hai giá trị hợp lệ 0 và 1; không phát hiện nhãn ngoài miền. Các trường định danh được kiểm tra để bảo đảm tính nhất quán của quan hệ giữa đơn hàng, khách hàng và thông tin vận chuyển.

Dữ liệu chi tiết mặt hàng có 180.519 bản ghi. Việc tổng hợp về cấp đơn hàng cho ra 65.752 đơn, là cơ sở tính tỷ lệ giao trễ và xây dựng mô hình. Cần phân biệt số bản ghi chi tiết với số đơn hàng duy nhất khi trình bày kết quả.

3.2. Lưu trữ và khả năng tái sử dụng

Định dạng Parquet được lựa chọn cho dữ liệu đã xử lý vì có cấu trúc cột, hỗ trợ đọc lại thuận tiện bằng Spark và không phải thực hiện toàn bộ bước làm sạch mỗi lần mở notebook. Nhóm lưu riêng các bảng đã tách và một bảng tích hợp để phục vụ các mục đích khác nhau. Dữ liệu gốc được giữ riêng nhằm bảo đảm có thể đối chiếu khi cần.

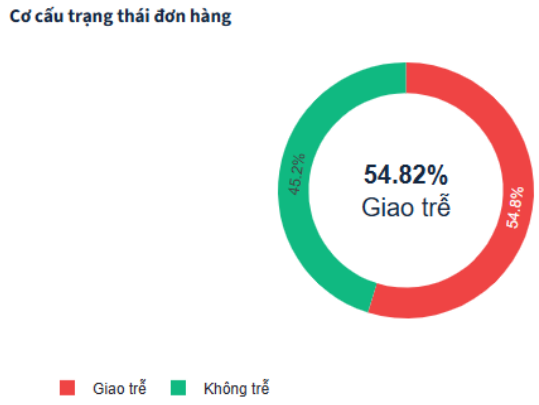
Các kết quả truy vấn Spark SQL được xuất thành tệp để phục vụ trực quan hóa. Mô hình cuối cùng cũng được lưu theo cấu trúc Spark ML Pipeline, nhờ đó có thể nạp lại để dự báo mà không phải huấn luyện từ đầu. Dashboard sử dụng các tệp CSV đã tổng hợp, giúp giao diện chạy độc lập với phiên Spark trên Colab.

Dữ liệu sau xử lý được lưu ở định dạng Parquet, giúp bảo toàn kiểu dữ liệu và hỗ trợ đọc theo cột trong Spark. Các bảng Parquet được sử dụng lại ở các bước phân tích, hạn chế phải đọc và tiền xử lý tệp CSV gốc trong mỗi lần thực nghiệm.

Các kết quả Spark SQL được xuất thành tệp CSV phục vụ trực quan hóa. Pipeline Random Forest cuối cùng được lưu riêng để có thể nạp lại khi cần kiểm thử. Notebook ghi lại các bước thực nghiệm nhằm hỗ trợ tái lập kết quả.

4. PHÂN TÍCH THỰC TRẠNG GIAO HÀNG

4.1. Tổng quan



Hình 1. Cơ cấu đơn hàng theo trạng thái giao

Về cách kiểm chứng, số lượng đơn hàng được tính theo mã đơn hàng duy nhất và so sánh với kết quả từ bảng orders sau khi tích hợp. Tương tự, số đơn trễ và đúng hạn được tính từ nhãn ở mức đơn hàng. Việc đối chiếu tổng số hai nhóm với tổng số đơn là một phép kiểm tra đơn giản

nhưng quan trọng: nếu tổng hai nhóm không bằng tổng số đơn, quá trình tạo nhãn hoặc phép nối cần được xem xét lại. Kết quả thống nhất mới được sử dụng cho biểu đồ tổng quan.

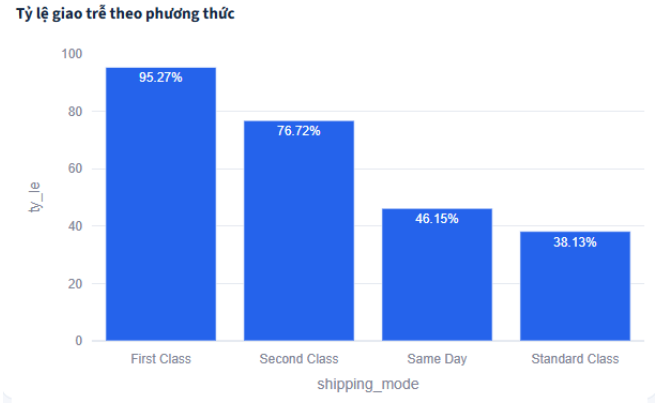
Để trình bày dễ hiểu, nhóm thể hiện tỷ lệ bằng biểu đồ donut và đặt số đơn ở phần chú thích. Tỷ lệ 54,82% cho thấy số đơn giao trễ nhỉnh hơn số đơn đúng hạn trong bộ dữ liệu được khảo sát. Đây là thông tin mô tả dữ liệu lịch sử, không phải xác suất giao trễ cho một đơn hàng bất kỳ trong tương lai. Phần dự báo ở các mục sau sử dụng mô hình riêng để ước lượng nguy cơ theo đặc điểm từng đơn.

Tỷ lệ giao trễ tổng thể được dùng làm mốc so sánh cho những phân tích tiếp theo. Một nhóm có tỷ lệ trễ cao hơn mức chung cần được xem xét cùng với quy mô số đơn, vì một nhóm rất ít đơn có thể cho tỷ lệ biến động mạnh. Do đó, các bảng phân tích thể hiện cả số lượng đơn lẫn tỷ lệ phần trăm.

Trên 65.752 đơn hàng, có 36.048 đơn giao trễ và 29.704 đơn đúng hạn. Tỷ lệ giao trễ là 54,82%, cho thấy số đơn trễ chiếm hơn một nửa tập dữ liệu được khảo sát.

Chỉ tiêu	Kết quả
Tổng đơn hàng	65.752
Giao trễ	36.048
Đúng hạn	29.704
Tỷ lệ giao trễ	54,82%

4.2. Phương thức vận chuyển



Hình 2. Tỷ lệ giao trễ theo phương thức vận chuyển

Về mặt thực hiện, truy vấn phân tích phương thức vận chuyển sử dụng phép nhóm theo trường shipping_mode. Số đơn trễ được tính bằng điều kiện trên nhãn giao trễ, sau đó chia cho tổng số đơn trong nhóm và nhân với 100 để có phần trăm. Kết quả được sắp xếp để xác định phương thức nào có tỷ lệ trễ cao nhất. Phần nhận xét đặt cạnh bảng số liệu giúp giải thích ý nghĩa của phép tổng hợp, đồng thời tạo cơ sở cho biểu đồ trong phần trực quan hóa.

Để tránh hiểu sai, nhóm phân biệt tỷ lệ giao trễ và số đơn giao trễ. Standard Class có số đơn lớn nên có thể đóng góp nhiều đơn trễ về số tuyệt đối, dù tỷ lệ trễ thấp hơn các phương thức khác. Ngược lại, First Class có tỷ lệ trễ rất cao nhưng quy mô đơn không lớn nhất. Việc đặt hai biểu đồ cạnh nhau giúp người xem nhận ra rằng hai câu hỏi "phương thức nào rủi ro cao nhất" và "phương thức nào có nhiều đơn trễ nhất" không hoàn toàn giống nhau.

Nhóm sử dụng Spark SQL để nhóm đơn hàng theo phương thức vận chuyển, tính số đơn và số đơn trễ, sau đó quy đổi thành tỷ lệ. Kết quả cho thấy First Class có tỷ lệ giao trễ 95,27%, Second Class 76,72%, Same Day 46,15% và Standard Class 38,13%. Sự chênh lệch này là một

trong những kết quả nổi bật của phân tích mô tả.

Khi diễn giải, nhóm không xem sự khác biệt tỷ lệ là bằng chứng một phương thức vận chuyển trực tiếp gây ra giao trễ. Tỷ lệ còn có thể liên quan đến thời hạn cam kết, đặc điểm đơn hàng và cách tổ chức giao nhận. Vì vậy, kết quả được dùng để nhận diện nhóm cần chú ý và gợi ý các yếu tố nên xem xét trong quá trình dự báo.

Phương thức	**Số đơn**	**Trễ (%)**
First Class	10.079	95,27
Second Class	12.778	76,72
Same Day	3.571	46,15
Standard Class	39.324	38,13

4.3. Phân tích khu vực và thời gian

Khi xem xét kết quả theo khu vực, nhóm sắp xếp tỷ lệ trễ theo thứ tự giảm dần và trình bày những nhóm nổi bật. Tuy nhiên, việc so sánh không chỉ dựa vào vị trí trên bảng xếp hạng; số lượng đơn cũng cần được xem cùng. Một vùng có tỷ lệ cao nhưng số lượng nhỏ có thể kém ổn định hơn vùng có hàng nghìn đơn. Bởi vậy, cách đọc biểu đồ luôn kết hợp cả tỷ lệ và quy mô mẫu.

Phân tích theo tháng và ngày trong tuần được thiết kế để kiểm tra xem tỷ lệ trễ có biến động theo chu kỳ hay không. Nhóm tính tổng số đơn và số đơn trễ cho từng mốc, sau đó tạo tỷ lệ theo cùng công thức với phần tổng quan. Biểu đồ đường giúp nhận biết xu hướng theo thời gian; biểu đồ cột giúp so sánh những nhóm thời gian rời rạc. Các nhận xét được giới hạn trong phạm vi dữ liệu quan sát.

Với yếu tố khu vực, nhóm tổng hợp theo vùng và xếp hạng các nhóm có tỷ lệ trễ cao. Với yếu tố thời gian, ngày đặt hàng được tách thành năm, tháng và ngày trong tuần để khảo sát biến động theo chu kỳ. Những phép biến đổi này được thực hiện từ trường thời gian đã chuẩn hóa, tránh việc xử lý chuỗi ngày tháng thiếu nhất quán.

Khi trực quan hóa, biểu đồ thanh ngang phù hợp để so sánh các khu vực có tên dài, còn biểu đồ đường phù hợp để quan sát xu hướng theo tháng. Các kết quả thời gian phản ánh giai đoạn có trong tập DataCo; nhóm không suy rộng chúng thành dự báo cho các năm ngoài phạm vi dữ liệu.

Nhóm sử dụng Spark SQL để thống kê theo vùng địa lý và các mốc thời gian đặt hàng. Một số vùng có tỷ lệ trễ cao hơn mức trung bình, chẳng hạn Central Africa (57,55%) và East Africa (56,77%). Sự khác biệt cần được xem cùng với quy mô mẫu của từng vùng, tránh đánh giá dựa trên tỷ lệ đơn lẻ.

Phân tích thời gian hỗ trợ quan sát biến động số đơn và tỷ lệ giao trễ theo năm, tháng hoặc ngày trong tuần. Các thống kê này được đưa lên Dashboard để người xem có thể đối chiếu nhiều chiều mà không phải chạy lại truy vấn Spark SQL.

4.4. Sản phẩm và quy mô đơn hàng

Phân tích sản phẩm được thực hiện từ bảng dòng đơn hàng đã liên kết với danh mục sản phẩm. Nhóm tính số đơn có chứa sản phẩm hoặc nhóm sản phẩm, rồi xác định số đơn trễ tương ứng. Với đơn hàng gồm nhiều dòng, cần dùng mã đơn hàng để hạn chế đếm trùng trong những bảng cần thống kê số đơn. Các phép tính này được

đặt trong Spark SQL để thuận tiện kiểm tra và đối chiếu với những bảng đã tạo ở phần tích hợp.

Đối với quy mô đơn hàng, nhóm xây dựng các nhóm theo số lượng mặt hàng hoặc giá trị đơn hàng và tính tỷ lệ trễ của từng nhóm. Phân nhóm giúp so sánh ở mức dễ đọc hơn so với việc liệt kê từng giá trị đơn lẻ. Trong phần nhận xét, nhóm chú ý cả xu hướng lẫn độ chênh lệch giữa các nhóm, không suy diễn rằng quy mô đơn hàng chắc chắn là nguyên nhân của giao trễ nếu kết quả quan sát không đủ rõ.

Những kết quả này có vai trò bổ sung cho phân tích vận chuyển và khu vực. Nếu tỷ lệ giữa các nhóm sản phẩm hoặc quy mô đơn không khác biệt lớn, nhóm ghi nhận đó là kết quả thực nghiệm thay vì cố diễn giải thành một mối quan hệ mạnh. Cách trình bày này giữ cho báo cáo nhất quán với dữ liệu quan sát được.

Phân tích sản phẩm cho thấy mức độ tập trung đơn hàng ở các nhóm hàng khác nhau. Đồng thời, thống kê theo số lượng mặt hàng hoặc giá trị đơn giúp đánh giá liệu đơn lớn có xu hướng giao trễ khác với đơn nhỏ hay không. Do một đơn có thể chứa nhiều sản phẩm, phép đếm DISTINCT theo danh mục không được cộng trực tiếp để suy ra tổng số đơn duy nhất.

5. XÂY DỰNG MÔ HÌNH DỰ BÁO

5.1. Xác định bài toán

Bài toán dự báo được xây dựng dưới dạng phân loại nhị phân. Nhãn 1 biểu thị đơn hàng có nguy cơ giao trễ, nhãn 0 biểu thị đơn hàng đúng hạn. Đơn vị dự báo là đơn hàng; do đó, dữ liệu học máy phải được tổng hợp đúng mức này trước khi chia tập. Nhóm không sử dụng các trường thể hiện trực tiếp kết quả giao hàng thực tế làm đầu vào.

Quy trình xây dựng mô hình được tách khỏi quy trình phân tích mô tả. Những biến có ích để giải thích kết quả đã xảy ra chưa chắc phù hợp để dự báo tại thời điểm đặt hàng. Đây là nguyên tắc quan trọng nhằm tránh rò rỉ thông tin và bảo đảm rằng mô hình có thể được sử dụng trong một kịch bản dự báo hợp lý.

Nhiệm vụ dự báo được xây dựng dưới dạng phân loại nhị phân: nhãn 1 biểu thị nguy cơ giao trễ và nhãn 0 biểu thị không giao trễ. Tập dữ liệu được tổng hợp ở cấp đơn hàng nhằm bảo đảm mỗi đơn chỉ xuất hiện một lần trong quá trình đánh giá.

Một nguyên tắc quan trọng là không sử dụng thông tin chỉ biết sau khi giao hàng, chẳng hạn số ngày vận chuyển thực tế hoặc ngày giao thực tế, làm đặc trưng đầu vào. Nếu sử dụng các biến này, mô hình có thể đạt kết quả ảo do rò rỉ thông tin từ tương lai.

5.2. Chuẩn bị đặc trưng

Một bước quan trọng của chuẩn bị đặc trưng là xác định thời điểm thông tin có sẵn. Nếu mục tiêu là dự báo ngay khi đơn hàng được đặt, mô hình chỉ được sử dụng những trường biết được ở thời điểm đó, chẳng hạn đặc điểm đơn hàng, khu vực và lựa chọn vận chuyển. Những biến liên quan trực tiếp đến ngày giao thực tế hoặc số ngày vận chuyển thực tế có thể tạo rò rỉ nhãn nếu đưa vào đầu vào. Do đó, nhóm phải tách rõ các biến dùng để tạo nhãn và các biến được phép dự báo.

Trong Pipeline, biến danh mục được chuyển thành biểu diễn số để thuật toán có thể tiếp nhận. Các bộ biến đổi được học từ dữ liệu huấn luyện, rồi áp dụng

thống nhất cho dữ liệu đánh giá. Cách tổ chức này hạn chế tình trạng cùng một danh mục bị mã hóa khác nhau giữa các tập. Sau mã hóa, các cột đặc trưng được gom thành một vector đầu vào và truyền cho thuật toán học máy trong cùng quy trình.

Đặc trưng dạng danh mục được mã hóa bằng StringIndexer và OneHotEncoder, sau đó ghép với các biến số qua VectorAssembler. Nhóm xây dựng Pipeline để toàn bộ các bước biến đổi và huấn luyện được thực hiện theo cùng một quy trình. Điều này giúp giảm sai lệch khi xử lý dữ liệu huấn luyện, đánh giá và dự báo.

Nhóm thử nghiệm các đặc trưng phản ánh khu vực, phương thức vận chuyển, lịch giao dự kiến và một số thuộc tính đơn hàng. Biến phân loại được mã hóa bằng các bước StringIndexer và OneHotEncoder; các biến sau xử lý được ghép thành vector đặc trưng bằng VectorAssembler.

Các bước học tham số trong pipeline phải được huấn luyện trên tập Train và áp dụng nhất quán cho Validation, Test. Điều này tránh việc sử dụng thông tin từ tập kiểm thử trong quá trình chuẩn bị mô hình.

5.3. Thiết kế thực nghiệm

Để lựa chọn mô hình, nhóm huấn luyện các thuật toán trên cùng tập đặc trưng và kiểm tra kết quả bằng các chỉ số thống nhất. Logistic Regression được sử dụng như phương án cơ sở dễ diễn giải, còn Random Forest có khả năng biểu diễn những quan hệ phi tuyến giữa các biến. Việc so sánh không dựa trên cảm nhận về thuật toán mà dựa trên kết quả đo được sau khi xử lý dữ liệu theo cùng một quy trình.

Đối với dữ liệu theo thời gian, việc phân chia tập cần tránh sử dụng thông tin của giai đoạn tương lai trong bước huấn luyện. Trong notebook, nhóm tổ chức các tập Train, Validation và Test theo giai đoạn để mô phỏng điều kiện dự báo. Tập Validation phục vụ lựa chọn phương án; tập Test được giữ để báo cáo kết quả cuối. Đây là bước quan trọng để hạn chế đánh giá quá lạc quan khi chỉ kiểm tra trên dữ liệu đã dùng huấn luyện.

Dữ liệu được chia theo các giai đoạn Train, Validation và Test để tách biệt huấn luyện, lựa chọn phương án và đánh giá cuối. Trên tập huấn luyện, nhóm xây dựng Logistic Regression làm mô hình đối chiếu và Random Forest làm mô hình cây tổ hợp. Các cấu hình được so sánh trên cùng cách chia dữ liệu để hạn chế ảnh hưởng của việc thay đổi tập mẫu.

Các chỉ số được sử dụng gồm Accuracy, Precision, Recall, Weighted F1-score và ROC-AUC. Accuracy cho biết tỷ lệ dự báo đúng; Precision và Recall mô tả chất lượng dự báo theo lớp; F1-score cân bằng hai chỉ số này; ROC-AUC phản ánh khả năng phân biệt giữa hai lớp trên nhiều ngưỡng. Nhóm không chỉ dựa vào một chỉ số khi kết luận.

Nhóm so sánh nhiều cấu hình và thuật toán phân loại, sau đó lựa chọn mô hình cuối cùng dựa trên kết quả đánh giá trên Validation. Tập Test được dành cho báo cáo hiệu quả cuối cùng. Các chỉ số gồm Accuracy, Precision, Recall, F1-score và ROC-AUC; riêng với bài toán giao trễ, Recall của lớp trễ cũng là một chỉ số đáng quan tâm.

6. KẾT QUẢ MÔ HÌNH

6.1. Mô hình được lựa chọn

Kết quả trên tập Test của Random Forest với 5 đặc trưng đạt Accuracy 69,49%, Weighted F1-score khoảng 0,6930 và ROC-AUC 0,7345. Đây là kết quả thực nghiệm cuối cùng được nhóm sử dụng để trình bày trong báo cáo và Dashboard. Các giá trị được ghi theo kết quả xuất từ notebook thay vì tính lại bằng số liệu làm tròn.

Sau quá trình thử nghiệm, nhóm lựa chọn Random Forest với 5 đặc trưng cho sản phẩm cuối. Trên tập Test, mô hình đạt Accuracy 69,49%, Weighted F1 khoảng 0,6930 và ROC-AUC 0,7345. Đây là mức hiệu quả trung bình, thể hiện mô hình có khả năng phân biệt hai nhóm tốt hơn dự đoán ngẫu nhiên nhưng vẫn còn sai số đáng kể.

Chỉ số	Giá trị Test
Accuracy	69,49%
Weighted F1	0,6930
ROC-AUC	0,7345

6.2. Thử nghiệm bổ sung đặc trưng

Quy trình so sánh các phương án được trình bày thành những bước có thể theo dõi: xác định danh sách đặc trưng, tạo Pipeline biến đổi tương ứng, huấn luyện trên dữ liệu Train, đánh giá trên Validation và kiểm tra mô hình cuối trên Test. Các bảng chỉ số được xuất để đặt cạnh nhau. Khi kết quả mở rộng không tốt hơn, nhóm không tiếp tục tăng số biến chỉ để làm mô hình phức tạp hơn, mà ưu tiên phương án gọn, có chỉ số kiểm thử rõ ràng.

Bài học rút ra từ thực nghiệm là lựa chọn đặc trưng phải dựa vào thời điểm dự báo và thông tin thực sự liên quan đến mục tiêu. Dữ liệu giao hàng còn chịu ảnh hưởng của nhiều yếu tố vận hành không được phản ánh đầy đủ trong bộ dữ liệu, nên việc thêm những biến sẵn có không bảo đảm cải thiện. Nhóm xem kết quả không tăng là một kết quả thực nghiệm có giá trị, giúp giải thích vì sao phương án 5 đặc trưng được lựa chọn để lưu và triển khai.

Nhóm thực hiện phương án mở rộng từ 5 lên 12 đặc trưng và so sánh các chỉ số đánh giá. Kết quả không cho thấy sự cải thiện rõ rệt so với mô hình đơn giản hơn. Điều đó cho thấy hiệu quả dự báo phụ thuộc vào chất lượng và mức độ liên quan của đặc trưng, không chỉ phụ thuộc vào số lượng biến được đưa vào.

Nhóm cũng đã thử nghiệm thêm dữ liệu thời tiết trong quá trình tìm phương án cải thiện. Tuy nhiên, phần notebook chính được trình bày ở đây tập trung vào các kết quả có bảng so sánh và đầu ra kiểm chứng được. Việc không chọn phương án mở rộng được giải thích theo kết quả thực nghiệm, không phải do nhóm bỏ qua bước thử nghiệm.

6.3. Diễn giải kết quả

Với mô hình phân loại nhị phân, một dự báo sai có thể thuộc hai dạng: cảnh báo giao trễ trong khi đơn thực tế đúng hạn, hoặc bỏ sót một đơn giao trễ. Hai dạng sai lệch có ý nghĩa vận hành khác nhau. Vì vậy, ma trận nhầm lẫn là phần bổ sung cần thiết cho Accuracy; nó cho phép người đọc quan sát mô hình đang thiên về dự báo lớp nào và dạng nhầm lẫn nào xuất hiện nhiều hơn.

ROC-AUC xấp xỉ 0,7345 cho thấy mô hình có khả năng phân biệt hai lớp ở mức nhất định nhưng vẫn còn khoảng cách so với một hệ thống dự báo đáng tin cậy.

Kết quả này phù hợp với mục tiêu của bài tập là triển khai quy trình Big Data và học máy hoàn chỉnh. Nhóm giữ nguyên kết quả chưa cao, trình bày rõ các thử nghiệm không cải thiện, thay vì thay đổi cách chia dữ liệu hoặc chỉ chọn những lần chạy có chỉ số tốt.

Các nguyên nhân tiềm năng làm giới hạn mô hình bao gồm thiếu thông tin vận hành ở từng chặng, trạng thái kho, lịch trình thực tế và những thay đổi phát sinh trong quá trình giao nhận. Đây là các giả thuyết về thông tin còn thiếu, không phải kết luận nhân quả rút ra trực tiếp từ dữ liệu DataCo.

Accuracy gần 70% không có nghĩa là mô hình dự báo đúng mọi tình huống; vẫn có những đơn giao trễ bị bỏ sót và đơn đúng hạn bị dự báo nhầm. Khi sử dụng trong vận hành, chi phí của hai loại sai số có thể khác nhau. Do đó, nếu áp dụng thực tế cần đánh giá thêm Recall của lớp trễ và lựa chọn ngưỡng cảnh báo phù hợp với mục tiêu nghiệp vụ.

7. TRỰC QUAN HÓA VÀ DASHBOARD

7.1. Thiết kế Dashboard

Để chuyển dữ liệu Spark sang giao diện Streamlit, nhóm xuất các bảng tổng hợp và kết quả dự báo thành các tệp CSV. Cách làm này tách lớp xử lý dữ liệu lớn khỏi lớp hiển thị, phù hợp với yêu cầu triển khai một trang web nhẹ. Các biểu đồ không cần truy vấn lại dữ liệu gốc mỗi khi người dùng chuyển trang, nhờ đó thao tác trên Dashboard thuận tiện hơn trong buổi trình bày.

Phần giao diện được thiết kế xoay quanh các câu hỏi đã đặt ra trong mục tiêu đề tài. Trang tổng quan trả lời quy mô và tỷ lệ giao trễ; các trang phân tích cho biết khác biệt theo khu vực, phương thức, thời gian và đơn hàng; trang đánh giá mô hình trình bày kết quả dự báo. Việc giữ cấu trúc thống nhất giữa notebook và Dashboard giúp đối chiếu số liệu dễ dàng.

Các bộ lọc giúp người xem tập trung vào một phần dữ liệu, còn các chỉ số tổng quan được hiển thị ở vị trí dễ quan sát. Nhóm sử dụng Plotly để tạo biểu đồ tương tác, cho phép đọc nhãn, so sánh giá trị và theo dõi sự thay đổi khi lựa chọn nhóm dữ liệu. Cách trình bày này phục vụ cả việc kiểm tra kết quả và thuyết trình.

Dashboard sử dụng các tệp data_analysis.csv và prediction_test.csv, giúp giảm phụ thuộc vào việc khởi động Spark trên máy chủ triển khai. Đây là lựa chọn phù hợp cho mục đích minh họa và báo cáo môn học.

7.2. Các dạng biểu đồ

Biểu đồ tròn dạng donut được dùng cho tỷ trọng đơn trễ và đúng hạn; biểu đồ cột và thanh ngang dùng để so sánh giữa các nhóm; biểu đồ đường thể hiện biến động theo thời gian; heatmap ma trận nhầm lẫn và đường ROC phục vụ phần đánh giá mô hình. Việc lựa chọn nhiều dạng biểu đồ dựa trên mục đích truyền đạt thông tin, không chỉ nhằm tăng số lượng hình.

Ở mỗi biểu đồ, nhóm ghi tiêu đề, tên trục và đơn vị khi phù hợp. Phần nhận xét tập trung vào xu hướng hoặc khác biệt nổi bật, tránh mô tả lại toàn bộ các con số đã có trên hình. Với các tỷ lệ, cần đặt chúng cạnh số lượng đơn tương ứng để tránh diễn giải sai từ nhóm có ít quan sát.

8. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

8.1. Kết luận

Nghiên cứu đã hoàn thành quy trình xử lý, tích hợp và phân tích dữ liệu DataCo bằng PySpark và Spark SQL, đồng thời xây dựng mô hình Random Forest để dự báo nguy cơ giao hàng trễ. Tập phân tích có 65.752 đơn hàng, tỷ lệ giao trễ 54,82%. Mô hình cuối đạt Accuracy 69,49% và ROC-AUC 0,7345 trên tập Test.

Các thử nghiệm mở rộng đặc trưng, tối ưu mô hình và tích hợp thêm dữ liệu thời tiết chưa mang lại cải thiện đáng kể. Vì vậy, nhóm lựa chọn mô hình 5 đặc trưng, đồng thời xây dựng Dashboard Streamlit để trình bày kết quả phân tích và dự báo theo cách trực quan, dễ tiếp cận.

8.2. Hạn chế và hướng phát triển

Khả năng dự báo còn ở mức trung bình do dữ liệu chưa phản ánh đầy đủ các yếu tố vận hành. Hướng tiếp theo là thu thập dữ liệu có sẵn tại thời điểm dự báo về trạng thái kho, đơn vị vận chuyển và tiến độ xử lý đơn hàng; đánh giá mô hình trên các giai đoạn mới; đồng thời xem xét ngưỡng cảnh báo theo chi phí bỏ sót đơn trễ.

8.3. Sản phẩm bàn giao

Sản phẩm gồm notebook Google Colab, các bảng Parquet tích hợp, kết quả phân tích Spark SQL, pipeline Random Forest cuối cùng, mã nguồn Dashboard và ứng dụng Streamlit đã triển khai. Đây là các thành phần có thể kiểm tra độc lập trong phạm vi đồ án.

TÀI LIỆU THAM KHẢO

[1] DataCo Smart Supply Chain Dataset, bộ dữ liệu sử dụng trong thực nghiệm của nhóm.

[2] Apache Software Foundation, Apache Spark Documentation: Spark SQL, DataFrames và MLlib, https://spark.apache.org/docs/latest/.

[3] Streamlit, Streamlit Documentation, https://docs.streamlit.io/.

[4] Plotly, Python Graphing Library Documentation, https://plotly.com/python/.

Liên kết sản phẩm

Mã nguồn: https://github.com/ttlinhnguyen205/BigData-Delivery-Prediction

Dashboard: https://dataco-delivery-prediction.streamlit.app/